

Laporan Praktikum Kontrol Cerdas

Nama : Permata Luthfiya Akram
NIM : 224308018
Kelas : TKA 6A
Akun Github (Tautan) : <https://github.com/permatalaa>
Student Lab Assistant : Yulia Brilianty

1. Judul Percobaan

Reinforcement Learning for Autonomous Control.

2. Tujuan Percobaan

Tujuan percobaan dari praktikum ini adalah sebagai berikut:

- Memahami konsep dasar Reinforcement Learning (RL) dalam sistem kendali.
- Mengimplementasikan agen RL menggunakan algoritma Deep Q-Network (DQN).
- Menggunakan OpenAI Gym sebagai simulasi lingkungan untuk pelatihan RL.
- Melatih dan menguji agen RL untuk mengontrol lingkungan secara otonom.
- Menggunakan GitHub untuk version control dan dokumentasi praktikum.

3. Landasan Teori

Dalam *machine learning*, terdapat kemajuan yang signifikan dalam pengembangan *Reinforcement Learning* (RL), khususnya dalam mengatasi berbagai masalah (Putra et al., 2024). *Reinforcement Learning* (RL) adalah sebuah teknik yang diterapkan oleh *smart agent* untuk memecahkan masalah dalam lingkungan baru. RL mampu menemukan cara untuk menyelesaikan masalah dengan menghasilkan *reward* secara maksimal, caranya *agent* akan melakukan *exploitation* yang artinya pengambilan keputusan untuk melakukan sesuatu berdasarkan informasi yang tersedia, dan *exploration* untuk pengambilan keputusan dengan melakukan sesuatu yang baru (Desyani et al., 2024). *Deep Q-Network* (DQN) merupakan pengembangan dari metode *Q-Learning* dari RL dengan penambahan *Deep Neural Network* (Putra et al., 2024).

Deep Q-Network (DQN) adalah algoritma dalam *reinforcement learning* yang menggabungkan *Q-learning* dengan jaringan saraf untuk menyelesaikan masalah kompleks, sehingga memungkinkan agen untuk belajar dari pengalaman dan membuat keputusan dalam lingkungan yang rumit (Baradja & Tjendrowasono, 2024).

OpenAI Gym merupakan pustaka pengembangan algoritma RL yang bersifat *open source* yang dibuat oleh tim OpenAI. Gym dibuat untuk memudahkan pengembangan algoritma RL, karena salah satu kendala yang dialami oleh banyak peneliti adalah tidak adanya standar dalam pengujian dan perbandingan dari algoritma yang dibuat. Dengan tidak adanya *environment* standar, akan sangat sulit mencoba dan mengulang hasil penelitian yang dibuat oleh peneliti lain. Pembuatan *environment* sendiri juga akan menambah waktu penelitian dan menghabiskan *resource* yang ada (Irvansyah, 2020).

4. Analisis dan Diskusi

Analisis

Berdasarkan program DQN yang digunakan dalam lingkungan Cartpole V1, agen dapat belajar memiliki kontrol yang memadai atas keseimbangan tiang setelah beberapa episode pelatihan. Pada awal pelatihan, agen sering tidak dapat mempertahankan keseimbangan karena tingkat Epsilon yang tinggi. Seiring waktu, Epsilon secara bertahap berkurang, dan agen mulai menggunakan pedoman terbaik yang telah mereka pelajari lebih banyak.

Parameter algoritma DQN sangat memengaruhi kinerja agen dalam menyelesaikan tugas pada lingkungan seperti CartPole dan MountainCar. Gamma menentukan seberapa besar agen memperhitungkan reward jangka panjang. Nilai gamma yang tinggi (misal 0.99) lebih sesuai untuk MountainCar karena agen perlu mengumpulkan momentum, sedangkan gamma yang lebih rendah (misal 0.95) cukup untuk CartPole yang berfokus pada keseimbangan langsung. Epsilon mengontrol tingkat eksplorasi, nilai awal tinggi (sekitar 1.0) memungkinkan agen mencoba berbagai aksi, yang krusial untuk menghindari local optima. Penurunan epsilon yang lambat (misal $\text{epsilon_decay}=0.995$) memberikan waktu yang cukup bagi agen untuk mengeksplorasi sebelum beralih ke eksploitasi kebijakan terbaiknya. Learning rate mengatur seberapa besar pembaruan bobot jaringan, di mana nilai rendah (sekitar 0.001) meningkatkan stabilitas pembelajaran, terutama dalam lingkungan kompleks seperti MountainCar.

Tantangan utama adalah menemukan keseimbangan antara eksplorasi dan eksploitasi. Agen perlu mencoba tindakan baru untuk menemukan strategi terbaik, sambil memanfaatkan pengetahuan yang sudah dipelajari. Jika eksplorasi berkurang terlalu cepat, agen bisa terjebak dalam strategi buruk. Selain itu, reward yang jarang atau tertunda, seperti pada MountainCar,

membuat agen sulit memahami bahwa terkadang perlu mundur terlebih dahulu untuk mencapai tujuan.

Diskusi

Perbedaan utama antara *Reinforcement Learning* (RL) dan *supervised learning* dalam sistem kontrol terletak pada metode agen pembelajaran. Saat belajar pemantauan, model dilatih menggunakan data yang ditandai, yang berarti bahwa input yang benar dan edisi yang benar telah diketahui sebelumnya. Sementara itu, di RL, agen pembelajaran dilakukan melalui interaksi langsung dengan lingkungan. Agen menerima umpan balik dalam bentuk hadiah atau hukuman yang diambil dalam langkah-langkah dan menggunakan informasi ini untuk secara bertahap meningkatkan strategi pengambilan keputusan mereka tanpa meminta data label eksplisit. Ini membuat RL sangat cocok untuk sistem kontrol yang dinamis dan kompleks.

Mengatur keseimbangan antara eksplorasi dan eksploitasi sangat penting untuk mengoptimalkan kinerja agen RL. Eksplorasi memungkinkan agen mencoba berbagai tindakan untuk menemukan strategi yang lebih efektif, sementara eksploitasi membuat agen memanfaatkan strategi terbaik yang telah dipelajari. Salah satu metode yang umum digunakan adalah *epsilon-greedy*, di mana agen memilih tindakan secara acak dengan probabilitas tertentu (epsilon) dan memilih tindakan dengan nilai Q tertinggi untuk sisanya. Dengan menurunkan nilai epsilon secara bertahap, agen dapat lebih banyak bereksplorasi di awal pelatihan, lalu beralih fokus ke eksploitasi setelah memperoleh cukup pengalaman.

Reinforcement Learning memiliki potensi besar untuk diterapkan pada berbagai sistem kendali di dunia nyata. Misalnya, mengatur lampu lalu lintas secara cerdas untuk mengoptimalkan arus kendaraan, mengontrol suhu dan ventilasi otomatis pada bangunan pintar, atau mengendalikan robot otonom yang dapat menyesuaikan gerakan sesuai kondisi lingkungan. RL juga berguna untuk sistem pemeliharaan prediktif, di mana agen dapat mempelajari pola keausan komponen dan mengambil tindakan pencegahan untuk menghindari kerusakan lebih serius. Kemampuan RL untuk belajar dari pengalaman membuatnya sangat cocok menghadapi tantangan dalam berbagai aplikasi kendali yang kompleks.

5. Assignment

Dalam tugas ini, program pelatihan dan pengujian agen dimodifikasi dengan mengganti environment dari *CartPole-v1* menjadi *MountainCar-v0*. Selain itu, pada program pelatihan, ditambahkan fitur *target network* yang diperbarui setiap 10 episode untuk meningkatkan stabilitas proses pembelajaran agen. Proses eksekusi program tetap sama seperti sebelumnya,


yaitu menjalankan program pelatihan terlebih dahulu, kemudian melanjutkan dengan program pengujian untuk mengevaluasi performa agen.

Hasil pelatihan dan pengujian pada environment *MountainCar* menunjukkan karakteristik yang berlawanan dibandingkan dengan *CartPole*. Pada *CartPole*, semakin tinggi skor yang dicapai, semakin baik agen dalam menjaga keseimbangan tiang di atas troli. Sebaliknya, pada *MountainCar*, skor yang lebih rendah justru menunjukkan kinerja yang lebih baik, karena agen mampu mencapai puncak bukit dengan lebih cepat. Ini disebabkan oleh sifat reward pada *MountainCar*, di mana agen mendapat nilai negatif hingga mencapai tujuan, sehingga skor rendah menunjukkan waktu pencapaian yang singkat.


Selain perbedaan dalam interpretasi skor, tujuan utama dari kedua environment juga berbeda. *CartPole* berfokus pada menjaga keseimbangan tiang dengan menggerakkan troli ke kiri atau kanan, sedangkan *MountainCar* mengharuskan agen mengayun maju-mundur untuk mengumpulkan momentum agar dapat mencapai puncak bukit.

6. Data dan Output Hasil Pengamatan

Sajikan data dan hasil yang diperoleh selama percobaan. Gunakan tabel untuk menyajikan data jika diperlukan.

No	Variabel	Hasil Pengamatan
1	Data hasil uji environment	Episode: 987/1000, Score: 170, Epsilon: 0.01 Episode: 988/1000, Score: 146, Epsilon: 0.01 Episode: 989/1000, Score: 117, Epsilon: 0.01 Episode: 990/1000, Score: 179, Epsilon: 0.01 Episode: 991/1000, Score: 389, Epsilon: 0.01 Episode: 992/1000, Score: 499, Epsilon: 0.01 Episode: 993/1000, Score: 229, Epsilon: 0.01 Episode: 994/1000, Score: 180, Epsilon: 0.01 Episode: 995/1000, Score: 202, Epsilon: 0.01 Episode: 996/1000, Score: 123, Epsilon: 0.01 Episode: 997/1000, Score: 187, Epsilon: 0.01 Episode: 998/1000, Score: 288, Epsilon: 0.01 Episode: 999/1000, Score: 56, Epsilon: 0.01 Episode: 1000/1000, Score: 68, Epsilon: 0.01
2	Hasil enviroentment CartPole	

3 Hasil environment MountainCar



7. Kesimpulan

Berdasarkan hasil eksperimen, dapat disimpulkan bahwa agen belum mampu mengontrol environment *MountainCar* secara optimal. Hal ini terlihat dari skor pelatihan yang tidak menurun secara signifikan, sehingga skor pengujian masih terlalu tinggi. Ini mengindikasikan bahwa agen kesulitan menemukan strategi yang efektif untuk mencapai tujuan dengan lebih efisien.

8. Saran

Untuk percobaan selanjutnya, dapat ditingkatkan performa agen dalam mengontrol *CartPole* dengan menyesuaikan parameter dan menambah jumlah episode pelatihan agar agen RL dapat belajar lebih baik dan mencapai kontrol optimal pada *CartPole*, serta pengimplementasian pada masalah yang ada di dunia nyata.

10. Daftar Pustaka

- Baradja, A., & Tjendrowasono, T. I. (2024). Pengaplikasian Deep Reinforcement Q-Learning Untuk Prediksi Perdagangan Valas Otomatis. *Jurnal Rekayasa Sistem Informasi dan Teknologi*, 1(3), 190–198. <https://doi.org/10.59407/jrsit.v1i3.519>
- Desyani, N., Kristina, S., & Yosephine, V. S. (2024). *Studi Awal Penerapan Reinforcement Learning pada Penyelesaian Heterogeneous Vehicle Routing Problem with Soft Time Windows. 1.*
- Irvansyah, M. (2020). *Implementasi Metode Reinforcement Learning Pada Simulasi Pergerakan Robot Multi-Sendi.*

Putra, R. A., Syahbana, Y. A., & Ananda. (2024). Implementasi Algoritma Deep Q-Network (DQN) pada Lampu Lalu Lintas Adaptif Berdasarkan Waktu Tunggu dan Arus Kendaraan. *The Indonesian Journal of Computer Science*, 13(5). <https://doi.org/10.33022/ijcs.v13i5.4372>